

รายงานปฏิบัติงานสหกิจศึกษา
ณ บริษัท ซีพีเอฟไอที เซ็นเตอร์ จำกัด

การเรียนรู้กระบวนการวิศวกรรมข้อมูล
The Data Engineer Learning Path

ธนธรณ์ บุญเชิด
640510658

สหกิจศึกษาเป็นส่วนหนึ่งของการศึกษาหลักสูตรปริญญาวิทยาศาสตรบัณฑิต
สาขาวิชาวิทยาการคอมพิวเตอร์
คณะวิทยาศาสตร์ มหาวิทยาลัยเชียงใหม่
ปีการศึกษา 2567

การเรียนรู้กระบวนการวิศวกรรมข้อมูล

The Data Engineer Learning Path

ธนธรณ์ บุญเชิด

640510658

สหกิจศึกษาเป็นส่วนหนึ่งของการศึกษาหลักสูตรปริญญาวิทยาศาสตรบัณฑิต

สาขาวิชาวิทยาการคอมพิวเตอร์

คณะวิทยาศาสตร์ มหาวิทยาลัยเชียงใหม่

ปีการศึกษา 2567

คณะกรรมการสอบสหกิจศึกษา

..... ประธานกรรมการ

(ผศ.ดร.ประภาพร เตชอังกูร)

..... กรรมการ

(ผศ.ดร.อารีรัตน์ ตรงรัมย์ทอง)

วันที่ เดือน พ.ศ.

กิตติกรรมประกาศ

การที่ข้าพเจ้าได้มาฝึกปฏิบัติงานสหกิจศึกษาในโครงการสหกิจศึกษา AXONS ภายใต้ บริษัท ซีพีเอฟ (ประเทศไทย) จำกัด (มหาชน) ตั้งแต่วันที่ 1 เมษายน 2567 ถึง 31 ตุลาคม 2567 ทำให้ข้าพเจ้าได้รับความรู้และประสบการณ์ที่มีคุณค่ามากมายจากการฝึกปฏิบัติงานสหกิจศึกษาสำหรับ รายงานสหกิจศึกษานับนี้สามารถสำเร็จไปได้ด้วยดีเนื่องจากด้วยความร่วมมือและสนับสนุนจากหลายฝ่ายดังนี้

- | | |
|---------------------------------|---|
| 1. ณัฐมน สิริวัฒนนันท์ | Director - IT Solution Food Business |
| 2. ณัฐธยา นามชู | Manager - Developer • Food Business Delivery |
| 3. ณัฐสิริ ดันติขจร | Manager - BI & AI • Sale & Distribution Delivery Team 1 |
| 4. บุษบา จันทรเศรฐ์ | BI Developer • Food Business Delivery |
| 5. ธนากร บุราคร | BI Developer • Food Business Delivery |
| 6. ธนาตล จริงจิตร | IT Solution Food Business Delivery |
| 7. ศิริรัตน์ บุรณะฤกษ์ศิริ | BI Developer • Food Business Delivery |
| 8. เสาวรส คงสัมฤทธิ์ | Outsource -TDA Food Business |
| 9. ผศ.ดร.ประภาพร เตชอังกูร | อาจารย์ที่ปรึกษาสหกิจศึกษา |
| 10. ผศ.ดร.อารีรัตน์ ตรงรัศมีทอง | กรรมการสอบโครงงานสหกิจ |

นอกจากนี้ ยังมีบุคคลท่านอื่น ๆ ที่ไม่ได้กล่าวถึง ณ ที่นี้ ซึ่งท่านเหล่านี้ได้กรุณาให้ความรู้ และคำแนะนำต่าง ๆ ที่เป็นประโยชน์แก่ข้าพเจ้าในระหว่างปฏิบัติงานข้าพเจ้าจึงใคร่ขอขอบพระคุณทุกท่านที่ได้มีส่วนร่วมในการให้ความรู้และคำแนะนำในด้านต่าง ๆ ที่เป็นประโยชน์ รวมถึงเป็นที่ปรึกษาในการจัดทำรายงานฉบับนี้จนเสร็จสมบูรณ์

หัวข้อสหกิจศึกษา	เรียนรู้กระบวนการวิศวกรรมข้อมูล
สถานประกอบการ	บริษัท ซีพีเอฟไอที เซ็นเตอร์ จำกัด
ผู้ดำเนินการศึกษา	640510658 ธนรรณ บัญเชิด
หลักสูตร	วิทยาศาสตร์บัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์
อาจารย์ที่ปรึกษาสหกิจ	ผู้ช่วยศาสตราจารย์ ดร.ประภาพร เตชอังกูร

บทคัดย่อ

การวิจัยนี้มุ่งศึกษากระบวนการวิศวกรรมข้อมูลเพื่อตอบสนองต่อความต้องการที่เพิ่มขึ้นในตลาดแรงงานด้านเทคโนโลยีสารสนเทศ ในปัจจุบัน องค์กรต่างๆ มีความต้องการใช้ข้อมูลเพื่อขับเคลื่อนการตัดสินใจและการดำเนินงานมากขึ้น ส่งผลให้เกิดความต้องการบุคลากรที่มีความเชี่ยวชาญในการจัดการข้อมูลอย่างมีประสิทธิภาพ การศึกษานี้เลือกใช้อุปกรณ์ไอพีอาร์ซึ่งเป็นเครื่องมือโอเพ่นซอร์สสำหรับการจัดการกระบวนการสกัด การแปลง และการโหลดเนื่องจากเป็นที่นิยมและใช้งานอย่างแพร่หลายในองค์กรชั้นนำ การเลือกหัวข้อและเครื่องมือนี้ช่วยให้สามารถศึกษาและเรียนรู้ได้โดยไม่ต้องใช้ข้อมูลภายในบริษัท ซึ่งเป็นการหลีกเลี่ยงการเผยแพร่ข้อมูลที่อาจเป็นความลับผลการวิจัยนี้จะช่วยเพิ่มความเข้าใจในกระบวนการวิศวกรรมข้อมูลและการใช้งานอุปกรณ์ไอพีอาร์ซึ่งเป็นประโยชน์ต่อการพัฒนาทักษะวิชาชีพในด้านวิศวกรรมข้อมูล และสามารถนำไปประยุกต์ใช้ในการทำงานจริงได้ในอนาคต

Title	The Data Engineer Learning Path
Company	CPF IT Center Co., Ltd.
Name	640510658 Thanaton Booncherd
Degree	Bachelor of Science in Computer Science
Advisor	Assistant Professor Dr.Prapaporn Techa-Angkoon

Abstract

This research aims to study the data engineering process to meet the increasing demand in the IT labor market. Today, organizations increasingly need to use data to drive decision-making and operations, resulting in a need for personnel with expertise in managing data effectively. This study selected Apache Airflow, an open-source tool for managing ETL (Extract, Transform, Load) processes, because it is popular and widely used in leading organizations. The selection of this topic and tool allows for study and learning without the need for internal company data, which avoids the disclosure of potentially confidential information. The results of this research will increase the understanding of the data engineering process and the use of Apache Airflow, which is beneficial for the development of professional skills in data engineering and can be applied in real work in the future.

สารบัญ

หัวข้อ	หน้า
กิตติกรรมประกาศ	ก
บทคัดย่อ	ข
Abstract	ค
สารบัญ	ง
สารบัญ (ต่อ)	จ
สารบัญรูป	ฉ
สารบัญตาราง	ช
บทที่ 1 บทนำ	1
1.1 ข้อมูลสถานประกอบการ	1
1.2 ตำแหน่งและลักษณะงานที่ได้รับมอบหมาย	1
1.3 หลักการและเหตุผล	2
1.4 วัตถุประสงค์	2
1.5 ประโยชน์ที่ได้รับ	2
1.6 ขอบเขต	3
1.7 เครื่องมือและอุปกรณ์ที่ใช้	3
1.8 แผนปฏิบัติงานสหกิจศึกษา	5
บทที่ 2 เอกสารและงานวิจัยที่เกี่ยวข้อง	6
2.1 Google Cloud Platform (GCP)	6
2.2 Microsoft Azure	7
2.3 Power BI	7
2.4 Pentaho	8
2.5 Apache airflow	8
2.6 Docker	10
2.7 Data Lake	10

สารบัญ (ต่อ)

หัวข้อ	หน้า
2.8 Data Warehouse	10
2.9 Data Pipeline	10
2.10 PostgreSQL	10
2.11 Beautifulsoup	10
2.12 Python	11
บทที่ 3 วิธีการดำเนินการวิจัย	11
3.1 ขั้นตอนการรวบรวมข้อมูลจากแหล่งข้อมูล	12
3.2 ขั้นตอนกระบวนการรวมข้อมูลจากหลายแหล่งไปยังพื้นที่เก็บข้อมูลส่วนกลางขนาดใหญ่ (ETL)	20
3.3 Data Lake	27
3.4 Data Warehouse	28
3.5 Data Visualization	29
บทที่ 4 ผลการดำเนินการวิจัย	31
4.1 ลักษณะผลลัพธ์ที่ได้จากกระบวนการ ETL	31
4.2 การอธิบายความสัมพันธ์ระหว่างข้อมูล	32
4.3 การวิเคราะห์ข้อมูลโดยใช้โปรแกรม Power BI	33
บทที่ 5 การทดสอบ	34
5.1 กรณีทดสอบแบบแยกหน้าที่การทำงานของแต่ละกระบวนการวิศวกรรมข้อมูล	34
บทที่ 6 บทสรุป	35
6.1 สรุปผลการดำเนินโครงการ	35
6.2 ข้อจำกัด	35
6.3 ข้อเสนอแนะ	35
6.4 สรุปผลการปฏิบัติงาน	35
เอกสารอ้างอิง (References)	36

สารบัญรูป

รูปที่	หน้า
รูปที่ 2.1 Files and commits	7
รูปที่ 2.2 XCom	9
รูปที่ 3.1 Systems Architecture	12
รูปที่ 3.2 Inflation Dag ที่แสดงผ่าน UI	20
รูปที่ 3.3 การสกัดข้อมูลหน้าเว็บ	22
รูปที่ 3.4 กระบวนการ Transform	24
รูปที่ 3.5 กระบวนการโหลดข้อมูลไปยัง Data Lake	26
รูปที่ 3.6 Data Lake Storage	27
รูปที่ 3.7 Data Warehouse	28
รูปที่ 3.8 การนำข้อมูลเข้าสู่ Power BI 1	29
รูปที่ 3.9 การนำข้อมูลเข้าสู่ Power BI 2	30
รูปที่ 3.10 การสร้าง Visual	30
รูปที่ 4.1 แสดงว่า Task ที่ถูกจัดการโดย Apache Airflow ไม่พบข้อผิดพลาด	31
รูปที่ 4.2 Log ของกระบวนการ write_website_data	31
รูปที่ 4.3 Sales Dashboards	33

สารบัญตาราง

ตารางที่	หน้า
ตารางที่ 1.8 แผนปฏิบัติงานสหกิจศึกษา	5
ตารางที่ 3.1 คุณลักษณะของข้อมูลจาก Olist_Customers_Dataset	13
ตารางที่ 3.2 คุณลักษณะของข้อมูลจาก Olist_Geolocation_Dataset	13
ตารางที่ 3.3 คุณลักษณะของข้อมูลจาก Olist_Order_Items_Dataset	14
ตารางที่ 3.4 คุณลักษณะของข้อมูลจาก Olist_Order_Payments_Dataset	15
ตารางที่ 3.5 คุณลักษณะของข้อมูลจาก Olist_Order_Reviews_Dataset	16
ตารางที่ 3.6 คุณลักษณะของข้อมูลจาก Olist_Orders_Dataset	17
ตารางที่ 3.7 คุณลักษณะของข้อมูลจาก Olist_Products_Dataset	18
ตารางที่ 3.8 คุณลักษณะของข้อมูลจาก Olist_Sellers_Dataset	19
ตารางที่ 3.9 คุณลักษณะของข้อมูลจาก Product_Category_Name_Translation	19
ตารางที่ 3.10 คุณลักษณะของข้อมูลจาก Inflation_rate	19
ตารางที่ 5.1 กรณีทดสอบ ผลลัพธ์ที่คาดหวัง และ ผลการทดสอบ	34

บทที่ 1

บทนำ

การปฏิบัติงานสหกิจครั้งนี้ผู้จัดทำได้ปฏิบัติงานที่ AXONS เป็นบริษัทเทคโนโลยีของไทยที่มีบทบาทสำคัญในการสนับสนุนความสำเร็จของบริษัท เจริญโภคภัณฑ์อาหาร จำกัด (มหาชน) หรือ CPF โดยเฉพาะในด้านเทคโนโลยีเกษตร (AgriTech) และการจัดการห่วงโซ่อาหารระดับโลก ซึ่งได้รับมอบหมายงานในตำแหน่ง BI Developer สร้างรายงานตามความต้องการของผู้ใช้

1.1 ข้อมูลสถานประกอบการ

1.1.1 ชื่อองค์กร

CPF IT Center Co., Ltd.

1.1.2 ระยะเวลาปฏิบัติงาน

1 เมษายน 2567 ถึง 31 ตุลาคม 2567

1.1.3 ลักษณะองค์กร

AXONS เชี่ยวชาญในการพัฒนาโซลูชันไอทีสำหรับธุรกิจเกษตรอุตสาหกรรมและอาหารแบบครบวงจร โดยเน้นการเพิ่มประสิทธิภาพและลดต้นทุนในกระบวนการผลิต ตั้งแต่การเพาะปลูก การเลี้ยงสัตว์ การแปรรูปอาหาร จนถึงการจัดการห่วงโซ่อุปทาน AXONS เป็นส่วนสำคัญในการขับเคลื่อนความสำเร็จของ CPF ในการเป็น "ครัวของโลก" และมุ่งสร้างมูลค่าเพิ่มให้กับเศรษฐกิจดิจิทัลของประเทศไทย

1.2 ตำแหน่งและลักษณะงานที่ได้รับมอบหมาย

1.2.1 ตำแหน่งงานที่ปฏิบัติ

- BI Developer

1.2.2 งานที่ได้รับมอบหมาย

- สร้างรายงานตามความต้องการของผู้ใช้
- สนับสนุนพี่เลี้ยงภายในทีมเพื่อให้ทีมสามารถทำงานได้ง่าย

1.2.3 ลักษณะงานที่ปฏิบัติ

- พัฒนาแดชบอร์ดตามความต้องการของผู้ใช้และจัดทำคู่มือการใช้งานแดชบอร์ด

- ใช้เครื่องมือ Power BI ในการสร้างแดชบอร์ดที่สามารถแสดงข้อมูลเชิงลึกได้ตามความต้องการของผู้ใช้ โดยเน้นการออกแบบที่สวยงามและใช้งานง่าย
- ใช้ PowerPoint ในการสร้างคู่มือการใช้งานแดชบอร์ดที่ชัดเจนและละเอียด เพื่อให้ ผู้ใช้สามารถทำความเข้าใจและใช้งานแดชบอร์ดได้อย่างมีประสิทธิภาพ
- ศึกษาเทคโนโลยีใหม่ ๆ พร้อมทั้งจัดทำคู่มือเทคโนโลยีหรือเครื่องมือใหม่ ๆ ที่สามารถนำมาใช้งานกับ Power BI ได้เพื่อให้สามารถสร้างเป็นแดชบอร์ดที่สามารถแสดงผลข้อมูลได้แบบ real time เช่น Power automate
- จัดทำคู่มือการออกแบบของ Power BI เพื่อสร้างเสริมความเข้าใจให้แก่ทีม UX/UI ได้เข้าใจถึงรูปแบบหรือข้อจำกัดที่ Power BI สามารถแสดงผลออกมาได้
- จัดทำ Data Dictionary

1.3 หลักการและเหตุผล

ปัจจุบัน AXONS มีการใช้งานผลิตภัณฑ์ของ Microsoft 365 อย่างยาวนานและเป็นเครื่องมือที่สามารถให้บริการผ่านระบบคลาวด์ จึงนำไปสู่การเลือกใช้ Power BI เพราะสามารถเข้าถึงแดชบอร์ดได้จากทุกที่ทุกเวลาและยังประหยัดค่า License สำหรับการเข้าใช้งานแดชบอร์ดอีกทั้งยังมีค่าบริการที่ถูกกว่าซอฟต์แวร์ประเภทเดียวกันและอัตราค่าบริการที่เกี่ยวข้องกับคราวด์ที่ไม่ได้สูงมากเนื่องจากแดชบอร์ดจำเป็นที่จะต้องมีการตั้งตารางเวลาสำหรับรีเฟรชข้อมูลเพื่อให้แดชบอร์ดเป็นปัจจุบันมากที่สุดเพื่อที่จะเปลี่ยนแปลงองค์กรให้สามารถขับเคลื่อนด้วยข้อมูล และมีการใช้เทคโนโลยีในการเก็บรวบรวมและวิเคราะห์ข้อมูลเพื่อเพิ่มประสิทธิภาพในกระบวนการผลิต ซึ่งข้อมูลที่ถูกรวบรวมจากฟาร์มและโรงงานแปรรูปจะถูกนำมาวิเคราะห์เพื่อปรับปรุงกระบวนการและลดต้นทุนการผลิตเพื่อให้สามารถแข่งขันกับผู้ค้ารายอื่น

1.4 วัตถุประสงค์

เพื่อพัฒนาแดชบอร์ดตามความต้องการของผู้ใช้เพื่อให้ผู้ใช้สามารถวิเคราะห์และทำความเข้าใจข้อมูลเชิงลึกอีกทั้งเป็นแดชบอร์ดที่สามารถทำความเข้าใจได้ง่ายและมีการเลือกใช้กราฟได้อย่างเหมาะสมกับการแสดงผลข้อมูล

1.5 ประโยชน์ที่ได้รับ

- ผู้ใช้สามารถใช้ข้อมูลจากแดชบอร์ดในการตัดสินใจดำเนินกิจกรรมบางอย่างที่สำคัญอย่างมีเหตุผลและมีข้อมูลสนับสนุน ทำให้สามารถเพิ่มประสิทธิภาพในการทำงาน
- นักศึกษาได้รับประสบการณ์ในการพัฒนาแดชบอร์ด และได้ความรู้ที่เกี่ยวข้องกับธุรกิจ

1.6 ขอบเขต

การพัฒนาแดชบอร์ดที่มีความถูกต้องของข้อมูลและตรงตามความต้องการของผู้ใช้ อีกทั้งแดชบอร์ดสามารถใช้งานได้ง่าย

1.6.1 ขอบเขตของระบบงาน

- การเก็บรวบรวมความต้องการของผู้ใช้
- จำลองต้นแบบรายงาน
- แก้ไขต้นแบบรายงาน
- ส่งมอบต้นแบบที่แก้ไข
- พัฒนาแดชบอร์ด
- ส่งมอบ Final Report หากมีข้อผิดพลาดดำเนินการแก้ไขและส่งมอบภายหลัง
- ส่งมอบคู่มือการใช้งานให้แก่ผู้ใช้
- สามารถส่งมอบรายงานให้แก่ผู้ใช้ได้ภายในกรอบเวลาที่กำหนด

1.6.2 ขอบเขตของข้อมูล

ลักษณะของข้อมูลที่มีการใช้เป็นข้อมูลที่เกี่ยวข้องกับสินค้าที่มีการผลิตและส่งออกไปยังโซนยุโรปโดยมีทั้งหมด 16 Feature 496 Row โดยมี Feature ที่เกี่ยวข้องคือ 1) รหัสสินค้า 2) ชื่อสินค้า 3) ประเภทกรรมวิธีที่ใช้ผลิตสินค้า 4) วันที่ผลิต 5) โรงงานที่ผลิต 6) ชื่อลูกค้า 7) ประเทศที่อยู่ของลูกค้าเป็นต้น โดยข้อมูลที่มีการใช้จะถูกจำกัดสิทธิการเข้าถึงโดยแบ่งเป็น สิทธิระดับ Project Dataset และ Table

1.7 เครื่องมือและอุปกรณ์ที่ใช้

1.7.1 เครื่องมือในด้านฮาร์ดแวร์

- คอมพิวเตอร์ส่วนบุคคล CPU 6 Core, Ram 16 GB, SSD 512 GB
- Virtual machine CPU 8 Core, Ram 64 GB, HDD 1 TB

1.7.2 เครื่องมือในด้านซอฟต์แวร์

- BigQuery เป็นระบบจัดการฐานข้อมูลขนาดใหญ่ที่พัฒนาโดย Google ซึ่งอยู่ในกลุ่ม Google Cloud Platform (GCP) โดย BigQuery ออกแบบมาเพื่อให้สามารถจัดการและวิเคราะห์ข้อมูลขนาดใหญ่ได้อย่างมีประสิทธิภาพ รวดเร็ว และสามารถขยายตัวได้โดยใช้ภาษา SQL ในการเขียนคำสั่งและการดึงข้อมูล

- Power BI เป็นเครื่องมือทางธุรกิจ (Business Intelligence: BI) ที่พัฒนาโดยบริษัท Microsoft สำหรับการวิเคราะห์และแสดงผลข้อมูลในรูปแบบกราฟิก (Dashboard) ที่มีประสิทธิภาพ Power BI ช่วยให้ผู้ใช้สามารถเข้าถึงข้อมูล วิเคราะห์ และนำเสนอข้อมูลได้อย่างมีประสิทธิภาพผ่านการสร้างรายงานและแดชบอร์ดที่สวยงามและใช้งานง่าย
- Pentaho เป็นเครื่องมือที่ใช้สำหรับสร้างและจัดการ ETL (Extract, Transform, Load) Pipeline อย่างมีประสิทธิภาพ เครื่องมือนี้ถูกออกแบบมาเพื่อให้ง่ายต่อการใช้งานและสามารถจัดการกับข้อมูลจากแหล่งข้อมูลต่าง ๆ
- Azure Repo ใช้สำหรับการจัดการ Source Code และสคริปต์ต่าง ๆ และใช้สำหรับการใช้งาน Versioning Control คล้ายคลึง Git Hub
- Pipeline ใน Azure DevOps ถูกใช้เพื่อสร้างและจัดการ CI/CD ที่จะทำให้การขนย้ายข้อมูลไปยัง GCP เป็นไปโดยอัตโนมัติ
- Apache Airflow เป็นเครื่องมือในการสร้าง Data Pipeline ซึ่งสามารถเขียนโปรแกรมมาควบคุมการไหลของข้อมูลได้และยังสามารถสร้างและควบคุมกระบวนการ ETL
- Azure Data Lake Gen2 ช่วยให้สามารถจัดการกับข้อมูลจากแหล่งต่าง ๆ ได้ในที่เดียว และสามารถนำข้อมูลเหล่านั้นไปใช้ในอนาคตได้ตามต้องการ
- Azure Synapse Analytics จัดการกับข้อมูลที่ถูกโครงสร้างและผ่านการแปลงแล้ว ทำให้การเข้าถึงข้อมูลเพื่อวิเคราะห์เป็นไปได้อย่างรวดเร็ว
- Docker ใช้สำหรับการสร้างสภาพแวดล้อมให้กับ Apache Airflow
- PostgreSQL ใช้สำหรับเป็นที่เก็บข้อมูลในการแลกเปลี่ยนข้อมูลระหว่าง Task ใน Apache Airflow

1.8 แผนปฏิบัติงานสหกิจศึกษา

ตารางที่ 1.8 แผนปฏิบัติงานสหกิจศึกษา

ลำดับ	หัวข้องาน	พ.ศ. 2567					
		เมษายน	พฤษภาคม	มิถุนายน	กรกฎาคม	สิงหาคม	กันยายน
1	เรียนรู้ขั้นตอนการทำงาน						
2	เลือกหัวข้อโปรเจกต์ที่ต้องการ						
3	รับความต้องการ						
4	จำลองต้นแบบรายงาน						
5	พัฒนาแดชบอร์ด						
6	ส่งมอบคู่มือและแดชบอร์ด						
7	จัดทำเอกสารรายงานปฏิบัติสหกิจศึกษา						

บทที่ 2

เอกสารและงานวิจัยที่เกี่ยวข้อง

ในบทนี้จะอธิบายเกี่ยวกับหลักการเบื้องต้นรวมถึงเครื่องมือและทฤษฎีที่เกี่ยวข้องในการพัฒนาและสร้าง Dashboard ด้วย Power BI ซึ่งเป็นงานหลักที่ผู้จัดทำได้ปฏิบัติในตำแหน่ง BI Developer โดยมีหัวข้อทั้งหมด 4 หัวข้อประกอบไปด้วย 2.1) Google Cloud Platform (GCP) 2.2) Microsoft Azure 2.3) Power BI 2.4) Pentaho และได้มีการเสริมในส่วนของการศึกษาเรื่อง Data engineer เพื่อทดแทนงานในส่วนที่ไม่ได้รับอนุญาตให้นำเสนอโดยมีหัวข้อทั้งหมด 7 หัวข้อประกอบไปด้วย 2.5) Apache airflow 2.6) Docker 2.7) Data Lake 2.8) Data warehouse 2.9) Data Pipeline 2.10) PostgreSQL 2.11) BeautifulSoup 2.12) Python

2.1 Google Cloud Platform (GCP)


Google Cloud Platform (GCP) [1] คือชุดบริการประมวลผลแบบคลาวด์ที่ให้บริการโดย Google ให้บริการที่หลากหลาย รวมถึงพลังการประมวลผล พื้นที่เก็บข้อมูล ฐานข้อมูล การเรียนรู้ของเครื่อง เครือข่าย และอื่นๆ อีกมากมาย ทั้งหมดนี้จัดส่งผ่านทางอินเทอร์เน็ต GCP ช่วยให้ธุรกิจสร้าง ปรับใช้ และปรับขนาดแอปพลิเคชันและบริการได้อย่างรวดเร็วและมีประสิทธิภาพ โดยไม่จำเป็นต้องลงทุนหรือจัดการโครงสร้างพื้นฐานทางกายภาพ

- Cloud Storage [2] เป็นบริการใน Google Cloud ที่ใช้สำหรับจัดเก็บไฟล์หรือข้อมูลต่างๆ ในบัคเก็ต (Buckets) โดยบัคเก็ตนี้สามารถจัดเป็นกลุ่มในโปรเจกต์และสามารถจัดกลุ่มโปรเจกต์ให้อยู่ในองค์กรเดียวกันได้ นอกจากนี้ยังสามารถกำหนดสิทธิ์การเข้าถึงข้อมูลให้กับบุคคลที่กำหนดหรือเปิดให้ทุกคนบนอินเทอร์เน็ตเข้าถึงได้ ซึ่งทำให้การจัดการข้อมูลเป็นไปได้อย่างมีประสิทธิภาพและสะดวกสบาย
- Google BigQuery [3] เป็นคลังข้อมูลแบบไร้เซิร์ฟเวอร์ (Serverless Data Warehouse) บนระบบคลาวด์ (Cloud Data Warehouse) ที่พัฒนาโดย Google ช่วยให้ผู้ใช้สามารถจัดเก็บ วิเคราะห์ และดึงข้อมูลเชิงลึกจากข้อมูลขนาดใหญ่ (Big Data) ได้อย่างรวดเร็ว มีประสิทธิภาพ และคุ้มค่า เหมาะกับธุรกิจทุกขนาดที่ต้องการวิเคราะห์ข้อมูลเพื่อนำไปต่อยอดทางธุรกิจ

2.2 Microsoft Azure

Microsoft Azure [4] เป็นแพลตฟอร์มการประมวลผลแบบคลาวด์และชุดบริการคลาวด์ที่ให้บริการโดย Microsoft โดยให้บริการและโซลูชันที่หลากหลายบนคลาวด์ เพื่อให้องค์กรสามารถสร้าง, นำไปใช้งาน และจัดการแอปพลิเคชันและบริการต่างๆ ได้ผ่านเครือข่ายศูนย์ข้อมูลทั่วโลกของ Microsoft

- Azure Repos [5] เป็นบริการของ Microsoft Azure ที่ใช้สำหรับโฮสต์ซอร์สโค้ดผ่านระบบ Git ซึ่งเป็นระบบจัดการเวอร์ชัน (Version Control System: VCS) ซึ่งมีการจัดการ ดังรูป 2.1 ที่ช่วยเก็บไฟล์หรือข้อมูลที่ถูกแก้ไขในโปรเจกต์ทั้งหมด นักพัฒนาสามารถย้อนกลับไปดูประวัติการแก้ไข (Commit) ได้ ทำให้สามารถตรวจสอบและติดตามการเปลี่ยนแปลงได้อย่างมีประสิทธิภาพ หากเกิดปัญหาในการพัฒนาระบบสามารถตรวจสอบประวัติย้อนหลังได้ตั้งแต่เริ่มต้นจนถึงปัจจุบัน



รูปที่ 2.1 Files and commits

- Azure Pipelines [6] เป็นส่วนหนึ่งของ Azure DevOps ที่ทำหน้าที่สร้าง, ทดสอบ, และปรับใช้โค้ดโปรเจกต์โดยอัตโนมัติ โดยรองรับทุกภาษาและแพลตฟอร์ม สามารถทำงานร่วมกับ Azure Repo การใช้งาน Azure Pipelines สำหรับการสร้าง CI/CD
- Azure Data Lake Gen2 [7] เป็นที่เก็บข้อมูลแบบที่เป็นมีโครงสร้างและไม่มีโครงสร้างอีกทั้งสามารถเก็บข้อมูลดิบ
- Azure Synapse Analytics [8] เป็นชุดเครื่องมือใหม่จาก Microsoft ที่ช่วยให้เราทำ Analytics ได้เร็วขึ้น และ เป็นแบบ real time และ ซึ่งรวมชุดเครื่องมือที่รองรับทั้ง Data ที่ข้อมูลที่มีโครงสร้างและข้อมูลที่ไม่มีโครงสร้าง

2.3 Power BI

Power BI [9] เป็นเครื่องมือที่ช่วยเปลี่ยนข้อมูลซับซ้อนให้กลายเป็นข้อมูลเชิงลึกที่เข้าใจง่าย โดยมีองค์ประกอบสำคัญคือ แดชบอร์ด แบบจำลองความหมาย และรายงาน รายงานเป็นการแสดงภาพข้อมูลจากแบบจำลองความหมายเดียวกัน ผู้ใช้สามารถสร้างและแชร์รายงานในพื้นที่ทำงานหรือแอปได้

แบบจำลองความหมายเป็นการรวบรวมข้อมูลจากแหล่งต่าง ๆ ซึ่งสามารถเชื่อมต่อและนำเข้าผ่าน Power BI Desktop แดชบอร์ดเป็นพื้นที่แสดงไทม์ไลน์ข้อมูลจากรายงานหรือแหล่งอื่น ๆ ซึ่งช่วยให้ผู้ใช้สามารถตรวจสอบและตัดสินใจได้อย่างรวดเร็ว การรวมองค์ประกอบเหล่านี้ทำให้ Power BI เป็นเครื่องมือที่ทรงพลังในการวิเคราะห์และแสดงผลข้อมูลสำหรับองค์กร

- รายงานใน Power BI [10] คือหน้าเพจที่มีภาพการแสดงผลข้อมูล (วิช่วล) อย่างน้อยหนึ่งหน้า เช่น แผนภูมิเส้น แผนที่ และทรีแมป ทุกภาพการแสดงผลข้อมูลในรายงานจะมาจากแบบจำลองความหมายเดียวกัน สามารถสร้างรายงานเองหรือร่วมกับเพื่อนร่วมงาน และสามารถแชร์ได้โดยตรงในพื้นที่ทำงานหรือเป็นส่วนหนึ่งของแอป รายงานสามารถสร้างขึ้นโดยอัตโนมัติเมื่อเชื่อมต่อกับชุดข้อมูลจาก Excel, Power BI Desktop, ฐานข้อมูล หรือแอปพลิเคชัน SaaS เช่น แอปพลิเคชัน SaaS จะมีรายงานที่สร้างไว้ล่วงหน้า
- แบบจำลองความหมาย [11] คือการรวบรวมข้อมูลที่นำเข้าหรือเชื่อมต่อกับ Power BI Desktop ช่วยให้สามารถเชื่อมต่อและนำเข้าแบบจำลองความหมายจากแหล่งข้อมูลต่าง ๆ และรวมเข้าด้วยกันในที่เดียว แบบจำลองความหมายสามารถมาจากกระแสข้อมูลหรือแหล่งข้อมูลเช่น Excel, SQL Server Analysis Services (SSAS) หรือชุดข้อมูล Salesforce แบบจำลองความหมายที่เพิ่มโดยสมาชิกในพื้นที่ทำงานจะพร้อมใช้งานสำหรับสมาชิกอื่น ๆ ที่มีสิทธิ์
- แดชบอร์ด [12] เป็นพื้นที่ที่แสดงไทม์ไลน์ (Tiles) ซึ่งแต่ละไทม์ไลน์เป็นการแสดงผลข้อมูลจากรายงานหรือวิช่วลต่าง ๆ แดชบอร์ดสามารถสร้างและดูได้ในบริการของ Power BI เท่านั้น ไทม์ไลน์สามารถปักหมุดจากรายงาน Q&A แดชบอร์ดอื่น ๆ Excel SSRS หรือแม้แต่หน้ารายงานทั้งหมดก็ได้

2.4 Pentaho

Pentaho [13] เป็นเฟรมเวิร์ค Java ที่ใช้ในการสร้างโซลูชันด้าน Business Intelligence (BI) โดยมีซอฟต์แวร์ที่สำคัญเช่น Pentaho Data Integration (PDI) ที่ใช้ในการออกแบบการไหลของข้อมูล


- Pentaho Data Integration (PDI) [13] เป็นเครื่องมือจัดการข้อมูลแบบไร้โค้ดที่นอกเหนือจากการทำ ETL (Extract, Transform, Load) ยังสามารถผสานข้อมูลจากแหล่งต่าง ๆ ให้เป็นแหล่งข้อมูลเดียวที่ถูกต้อง เพื่อใช้เป็นฐานในการวิเคราะห์และรายงาน ซึ่งทำให้การจัดการข้อมูลเป็นไปอย่างมีประสิทธิภาพและรวดเร็วมากขึ้น โดยไม่จำเป็นต้องเขียนโค้ด

2.5 Apache airflow

Apache Airflow [14] เป็นแพลตฟอร์มโอเพนซอร์สสำหรับการจัดการ Workflow และ Data Pipeline ที่ซับซ้อน มันช่วยให้สามารถกำหนดตารางเวลา ตรวจสอบ และจัดการ Workflow ผ่าน Interface ที่ใช้งานง่าย ซึ่งสร้างขึ้นด้วยภาษา Python อีกทั้ง Airflow ยังรองรับการสร้าง Data Pipeline

แบบ Dynamic เพื่อเพิ่มความสามารถในการขยายตัว และการเพิ่มความสามารถในการทำงานอัตโนมัติ และการเพิ่มประสิทธิภาพกระบวนการทางวิศวกรรมข้อมูล

- Directed Acyclic Graph [15] เป็น Data Pipeline ที่ถูกเขียนด้วย Python แต่ละ DAG คือ กลุ่มก้อนของ Tasks ที่ถูกจัดระเบียบเพื่อแสดงความสัมพันธ์ของแต่ละ Tasks บนหน้า UI อีกทั้ง D-A-G เป็นตัวย่อมาจากคำดังต่อไปนี้
 - Directed: การทำงานมาต่อกันแต่ต้องมีอย่างน้อยหนึ่ง Task ที่เป็นตัวต้นทาง หรือ ปลายทาง
 - Acyclic: Airflow ไม่อนุญาตให้สามารถสร้าง Data Pipeline ที่วนกลับมาที่โหนดต้นทางได้ ไม่งั้นจะเกิดการลูปแบบไม่มีที่สิ้นสุด
 - Graph: งานทั้งหมดถูกจัดวางในโครงสร้างที่ชัดเจน และถูกเช็คความสัมพันธ์ของแต่ละงานไว้
- Tasks [15] เป็น node ที่อยู่ในแต่ละ DAG แสดงการทำงานแต่ละขั้นตอนใน Workflow โดยงานที่ Tasks ทำนั้นจะถูกกำหนดไว้ใน Operators
- Operators [15] คือ Building Blocks ของ Airflow ถูกใช้ในการกำหนดงานที่ต้องทำในแต่ละขั้นตอนของกระบวนการ เช่น PythonOperator และ BashOperator เป็นต้น
- Xcom [15] เป็นเครื่องมือที่ช่วยสามารถเข้าถึงข้อมูลกันระหว่าง DAG หรือระหว่าง Task ก็ได้ โดยจัดเก็บข้อมูลไว้รวมกันที่ศูนย์กลางที่เรียกว่า XCom ทุก Task สามารถเข้าถึง XCom ได้เหมือนทำให้ตัวแปร Local ย้ายไปอยู่ที่ Global สามารถส่งข้อมูลถึงกันได้โดยไม่จำเป็นต้องเป็น Task ที่อยู่ติดกัน โดยงานวิจัยนี้ XCom มีขนาดจำกัดที่ 1 GB เนื่องจากมีการเลือกใช้ฐานข้อมูลเป็นPostgres ซึ่งหลักการทำงานแสดงดังรูป 2.2



รูปที่ 2.2 XCom

2.6 Docker

Docker [16] เป็นซอฟต์แวร์ที่ช่วยให้สามารถ สร้าง ทดสอบ และติดตั้งแอปพลิเคชันใช้จริงได้อย่างรวดเร็ว Docker จะบรรจุซอฟต์แวร์ลงไปหน่วยที่เป็นมาตรฐานเรียกว่า คอนเทนเนอร์ ซึ่งจะมีทุกสิ่งที่ซอฟต์แวร์ต้องใช้ในการเรียกใช้งาน รวมทั้งไลบรารี เครื่องมือสำหรับระบบ โค้ด และรันไทม์ เมื่อใช้ Docker สามารถติดตั้งใช้จริงและปรับขนาดแอปพลิเคชันให้เหมาะกับทุกสภาพแวดล้อมและโค้ดจะถูกเรียกใช้ได้อย่างอย่างรวดเร็ว

2.7 Data Lake

Data lake [17] คือ ระบบที่ใช้เก็บข้อมูล Raw File เช่น ไฟล์ภาพ ไฟล์เสียง วิดีโอ และไฟล์อื่นๆ รวมทั้งข้อมูลที่เป็นแบบทั้ง Semi-Structured และ Unstructured

2.8 Data Warehouse

Data Warehouse [17] คือระบบที่รวบรวมข้อมูลจากแหล่งต่าง ๆ และนำเอามาเก็บไว้ให้อยู่ในรูปแบบที่มีโครงสร้างเพื่อ Query แล้วนำไปวิเคราะห์ และสนับสนุนการตัดสินใจต่าง ๆ ทางด้านธุรกิจ

2.9 Data Pipeline

Data Pipeline [18] คือกระบวนการในการสร้างเตรียมข้อมูลก่อนนำไปประมวลผลซึ่งมี 2 รูปแบบในการสร้าง Data pipeline โดยรูปแบบที่ 1) ETL และ 2) ELT โดยทั้งสองรูปแบบมีความแตกต่างในส่วนของการ T กับ L มีการสลับตำแหน่ง ถ้าหากเรานำ E กับ L มารวมกันจะเรียกว่า Data Ingestion

- Extract (E) การดึงข้อมูลจากแหล่งข้อมูลต่างๆ
- Load (L) การโหลดข้อมูล ไม่ว่าจะเป็นข้อมูลดิบ หรือข้อมูลที่ถูกแปลงแล้ว ไปที่ปลายทาง เช่น Data Warehouse หรือ Data Lake หรือระบบอื่นๆ
- Transform (T) เป็นการแปลงข้อมูลดิบจากแหล่งข้อมูลต่างๆ หรือจากระบบต่างๆ ให้มาอยู่ในรูปแบบที่เราสามารถนำไปวิเคราะห์ได้ หรือนำไปทำ Data Visualization ได้

2.10 PostgreSQL

PostgreSQL [19] คือ โปรแกรม OpenSource ที่สามารถนำไปใช้งานได้โดยไม่มีค่าใช้จ่ายใด เป็นระบบจัดการฐานข้อมูลแบบ Object-Relational Database Management System

2.11 Beautifulsoup

Beautifulsoup [20] คือ Python Library สำหรับดึงข้อมูลหน้าเว็บ หรือ HTML โดยทำหน้าที่ เป็น ตัว Parser ทำหน้าที่แปลงโครงสร้าง HTML ให้เป็นโครงสร้างข้อมูลที่สามารถนำมาใช้งานได้


2.12 Python

Python [21] คือหนึ่งในภาษาโปรแกรมระดับสูงที่ใช้กันอย่างแพร่หลาย ทั้งในการสร้างเว็บไซต์ พัฒนาซอฟต์แวร์ รวมถึงงานวิเคราะห์ข้อมูล โดยถูกออกแบบเพื่อให้มีโครงสร้างและ ไวยากรณ์ของ ภาษาที่ไม่ซับซ้อน เข้าใจง่าย มีการใช้พัฒนาแอปพลิเคชัน เว็บไซต์ รวมถึงแอปบนมือถือหรือ อุปกรณ์เคลื่อนที่ด้วย หน้าทีของ Python ก็คือการทำงานแปลชุดคำสั่งที่ละบรรทัดเพื่อป้อนเข้าสู่หน่วยประมวลผล ให้คอมพิวเตอร์ทำงานตามที่เรต้องการ หรือเรียกว่าการทำงานแบบ Interpreter นั่นเอง ด้วยภาษาที่ง่ายในการเขียน “Python” จึงมีความเหมาะสมสำหรับผู้เริ่มต้นเขียนโปรแกรมไปจนถึง นักพัฒนาในองค์กรบริษัทใหญ่

บทที่ 3

วิธีการดำเนินการวิจัย

ในบทนี้จะกล่าวถึงเหตุผลในการเลือกชุดข้อมูลและขั้นตอนและวิธีการดำเนินการวิจัย ในส่วนเหตุผลการเลือกข้อมูลชุดนี้เนื่องจากข้อมูลชุดนี้เป็นข้อมูลในลักษณะ Transaction และ Master และเพื่อให้สอดคล้องกับการฝึกงานที่มักจะพบข้อมูลในลักษณะนี้และเพื่อหลีกเลี่ยงการนำข้อมูลของบริษัทมาเผยแพร่ ขั้นตอนและวิธีการดำเนินการวิจัย แบ่งออกเป็น 5 ขั้นตอนหลัก ได้แก่ 3.1) ขั้นตอนการรวบรวมข้อมูลจากแหล่งข้อมูล (Source) 3.2) ขั้นตอนกระบวนการรวมข้อมูลจากหลายแหล่งไปยังพื้นที่เก็บข้อมูลส่วนกลางขนาดใหญ่ (ETL) 3.3) Data Lake 3.4) Data Warehouse 5) ขั้นตอนการนำข้อมูลมาแสดงเป็นภาพ (Data Visualization) ซึ่งแสดงดังรูป 3.1



รูปที่ 3.1 Systems Architecture

3.1 ขั้นตอนการรวบรวมข้อมูลจากแหล่งข้อมูล

ข้อมูลได้ทำการรวบรวมจาก Kaggle และ Website สาธารณะเพื่อหลีกเลี่ยงการนำข้อมูลของบริษัทมาเผยแพร่ ซึ่งข้อมูลที่ได้มาจาก Kaggle เป็นชุดข้อมูลจาก Olist ซึ่งเป็นแพลตฟอร์ม E-Commerce ในประเทศบราซิล โดยข้อมูลนี้ประกอบไปด้วยข้อมูลการสั่งซื้อสินค้าจากร้านค้า Olist ตั้งแต่ปี 2016 ถึง 2018 มีข้อมูลมากกว่า 100,000 รายการสั่งซื้อ ในส่วนของ Website สาธารณะได้ข้อมูลที่เกี่ยวข้องกับอัตราเงินเฟ้อของบราซิล สหรัฐอเมริกา สหภาพยุโรป และ โลก เนื่องจากทั้งสหรัฐอเมริกา สหภาพยุโรป ซึ่งเป็นคู่ค้าที่สำคัญของบราซิล โดยข้อมูลที่มีการนำมาใช้ได้ถูกอธิบายดังตารางด้านล่าง โดยข้อมูลจากตารางที่ 3.1.1 - 3.1.9 รวบรวมจาก <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce> และข้อมูล ตารางที่ 3.1.10 รวบรวมจาก <https://www.macrotrends.net/global-metrics/countries/BRA/brazil/inflation-rate-cpi> โดยแต่ละตารางมีข้อมูลที่เกี่ยวข้องดังต่อไปนี้ ตารางที่ 3.1 มีข้อมูลเกี่ยวข้องกับลูกค้าของแพลตฟอร์ม E-commerce ของ Olist ตารางที่ 3.2 มีข้อมูลเกี่ยวข้อง

กับภูมิศาสตร์ของพื้นที่ต่าง ๆ ในบราซิล ตารางที่ 3.3 มีข้อมูลเกี่ยวข้องกับรายการสินค้าที่ถูกสั่งซื้อในแต่ละคำสั่งซื้อผ่านแพลตฟอร์ม Olist ในบราซิล ตารางที่ 3.4 มีข้อมูลเกี่ยวข้องกับการชำระเงินในแต่ละคำสั่งซื้อบนแพลตฟอร์ม Olist ตารางที่ 3.5 มีข้อมูลเกี่ยวข้องกับการรีวิวคำสั่งซื้อของลูกค้าบนแพลตฟอร์ม Olist ตารางที่ 3.6 มีข้อมูลเกี่ยวข้องกับการสั่งซื้อทั้งหมดที่ทำผ่านแพลตฟอร์ม Olist ตารางที่ 3.7 มีข้อมูลเกี่ยวข้องกับคุณลักษณะของสินค้า ตารางที่ 3.8 มีข้อมูลเกี่ยวข้องกับผู้ขายในแพลตฟอร์ม E-commerce ของ Olist ตารางที่ 3.9 มีข้อมูลเกี่ยวข้องกับการซื้อสินค้าในแพลตฟอร์ม E-commerce ของ Olist ตารางที่ 3.10 มีข้อมูลเกี่ยวข้องกับการชำระเงินเพื่อในบราซิล

ตารางที่ 3.1 คุณลักษณะของข้อมูลจาก Olist_Customers_Dataset

ลำดับ	คุณลักษณะ	ชนิดของข้อมูล	คำอธิบาย	ตัวอย่างข้อมูล
1	customer_id	String	key to the orders dataset. Each order has a unique customer_id	06b8999e2fba1a1fbc88172c00ba8bc7
2	customer_unique_id	String	unique identifier of a customer.	861eff4711a542e4b93843c6dd7febb0
3	customer_zip_code_prefix	String	first five digits of customer zip code	14409
4	customer_city	String	customer city name	franca
5	customer_state	String	customer state	SP

ตารางที่ 3.2 คุณลักษณะของข้อมูลจาก Olist_Geolocation_Dataset

ลำดับ	คุณลักษณะ	ชนิดของข้อมูล	คำอธิบาย	ตัวอย่างข้อมูล
1	geolocation_zip_code_prefix	String	first 5 digits of zip code	1037
2	geolocation_lat	Double	latitude	-23.54562128115268
3	geolocation_lng	Double	longitude	-46.63929204800168
4	geolocation_city	String	city name	sao paulo
5	GeolocationState	String	state	SP

ตารางที่ 3.3 คุณลักษณะของข้อมูลจาก Olist_Order_Items_Dataset

ลำดับ	คุณลักษณะ	ชนิดของข้อมูล	คำอธิบาย	ตัวอย่างข้อมูล
1	order_id	String	order unique identifier	00010242fe8c5a6d1ba 2dd792cb16214
2	order_item_id	String	sequential number identifying number of items included in the same order.	1
3	product_id	String	product unique identifier	4244733e06e7ecb497 0a6e2683c13e61
4	seller_id	String	seller unique identifier	48436dade18ac8b2bce 089ec2a041202
5	shipping_limit_date	String	shows the seller shipping limit date for handling the order over to the logistic partner.	2017-09- 19T09:45:35.0000000
6	price	Double	item price	58.9
7	freight_value	Double	item freight value item (if an order has more than one item the freight value is splitted between items)	13.29

ตารางที่ 3.4 คุณลักษณะของข้อมูลจาก Olist_Order_Payments_Dataset

ลำดับ	คุณลักษณะ	ชนิดของข้อมูล	คำอธิบาย	ตัวอย่างข้อมูล
1	order_id	String	unique identifier of an order.	b81ef226f3fe1789b1e8 b2acac839d17
2	payment_sequential	String	a customer may pay an order with more than one payment method. If he does so, a sequence will be created to accommodate all payments.	1
3	payment_type	String	method of payment chosen by the customer.	credit_card
4	payment_installments	String	number of installments chosen by the customer.	8
5	payment_value	Double	transaction value.	99.33

ตารางที่ 3.5 คุณลักษณะของข้อมูลจาก Olist_Order_Reviews_Dataset

ลำดับ	คุณลักษณะ	ชนิดของข้อมูล	คำอธิบาย	ตัวอย่างข้อมูล
1	review_id	String	unique review identifier.	7bc2406110b926 393aa56f80a40eb a40
2	order_id	String	unique order identifier	73fc7af87114b39 712e6da79b0a37 7eb
3	review_score	Double	note ranging from 1 to 5 given by the customer on a satisfaction survey.	4
4	review_comment_title	String	comment title from the review left by the customer, in Portuguese.	(NULL)
5	review_comment_message	String	comment message from the review left by the customer, in Portuguese.	(NULL)
6	review_creation_date	Date	shows the date in which the satisfaction survey was sent to the customer.	2018-01-18T00:00:00.000000
7	review_answer_timestamp	Timestamp	Shows satisfaction survey answer timestamp.	2018-01-18T21:46:59.000000

ตารางที่ 3.6 คุณลักษณะของข้อมูลจาก Olist_Orders_Dataset

ลำดับ	คุณลักษณะ	ชนิดของข้อมูล	คำอธิบาย	ตัวอย่างข้อมูล
1	order_id	String	unique identifier of the order.	e481f51cbdc5467 8b7cc49136f2d6af 7
2	customer_id	String	key to the customer dataset. Each order has a unique customer_id.	9ef432eb6251297 304e76186b10a92 8d
3	order_status	String	Reference to the order status (delivered, shipped, etc).	delivered
4	order_purchase_timestamp	Timestamp	Shows the purchase timestamp.	2/10/2017 10:56
5	order_approved_at	String	Shows the payment approval timestamp.	2/10/2017 11:07
6	order_delivered_carrier_date	Date	Shows the order posting timestamp. When it was handled to the logistic partner.	4/10/2017 19:55
7	order_delivered_customer_date	Date	Shows the actual order delivery date to the customer.	10/10/2017 21:25
8	order_estimated_delivery_date	Date	Shows the estimated delivery date that was informed to customer at the purchase moment.	18/10/2017 0:00

ตารางที่ 3.7 คุณลักษณะของข้อมูลจาก Olist_Products_Dataset

ลำดับ	คุณลักษณะ	ชนิดของข้อมูล	คำอธิบาย	ตัวอย่างข้อมูล
1	product_id	String	unique product identifier	1e9e8ef04dbcff4541ed 26657ea517e5
2	product_category_name	String	root category of product, in Portuguese.	perfumaria
3	product_name_lenght	Double	number of characters extracted from the product name.	40
4	product_description_lenght	Double	number of characters extracted from the product description.	287
5	product_photos_qty	Double	number of product published photos	1
6	product_weight_g	Double	product weight measured in grams.	225
7	product_length_cm	Double	product length measured in centimeters.	16
8	product_height_cm	Double	product height measured in centimeters.	10
9	product_width_cm	Double	product width measured in centimeters.	14

ตารางที่ 3.8 คุณลักษณะของข้อมูลจาก Olist_Sellers_Dataset

ลำดับ	คุณลักษณะ	ชนิดของข้อมูล	คำอธิบาย	ตัวอย่างข้อมูล
1	seller_id	String	seller unique identifier	3442f8959a84dea7ee197c632cb2df15
2	seller_zip_code_prefix	String	first 5 digits of seller zip code	13023
3	seller_city	String	seller city name	campinas
4	seller_state	String	seller state	SP

ตารางที่ 3.9 คุณลักษณะของข้อมูลจาก Product_Category_Name_Translation


ลำดับ	คุณลักษณะ	ชนิดของข้อมูล	คำอธิบาย	ตัวอย่างข้อมูล
1	product_category_name	String	category name in Portuguese	beleza_saude
2	product_category_name_english	String	category name in English	health_beauty

ตารางที่ 3.10 คุณลักษณะของข้อมูลจาก Inflation_rate

ลำดับ	คุณลักษณะ	ชนิดของข้อมูล	คำอธิบาย	ตัวอย่างข้อมูล
1	year	String	Year	2023
2	Brazil	Double	Inflation in Brazil	4.59
3	Eu	Double	Inflation in EU	6.3
4	US	Double	Inflation in US	4.12
5	World	Double	Inflation in World	5.8

3.2 ขั้นตอนกระบวนการรวมข้อมูลจากหลายแหล่งไปยังพื้นที่เก็บข้อมูลส่วนกลางขนาดใหญ่ (ETL)

กระบวนการ ETL ซึ่งประกอบไปด้วย 3 ขั้นตอนดังนี้ 1. Extract 2. Transform 3. Load ซึ่งขั้นตอนทั้งหมดจะถูกบริหารจัดการด้วย Apache airflow ซึ่งเรียกว่า Dag (Directed Acyclic Graph) ตามรูป 3.2 และภายใน Dag จะประกอบไปด้วย task ต่าง ๆ ดังนี้ 1. Extract 2. Load 3. Transform และอีกข้อดีหนึ่งของการใช้ Apache airflow คือเราสามารถตั้ง Scheduler เพื่อให้กระบวนการทั้งหมดเป็นแบบอัตโนมัติ



รูปที่ 3.2 Inflation Dag ที่แสดงผ่าน UI

3.2.1 Extract

Extract คือ กระบวนการดึงข้อมูลจากแหล่งของข้อมูลจากแหล่งอื่น ๆ ในส่วนของงานวิจัยนี้ ได้ใช้ BeautifulSoup ซึ่งเป็น Python library สำหรับสกัดข้อมูลหน้าเว็บซึ่งจะไปกอบไปด้วยขั้นตอนดังต่อไปนี้ ซึ่งโค้ดจะถูกแสดงดังรูปที่ 3.3

1) Input

- ฟังก์ชัน `get_data_page(url)` รับค่า URL ของเว็บไซต์ที่ต้องการดึงข้อมูลมา
- ฟังก์ชัน `get_data_data(html)` รับค่า HTML ของหน้าเว็บที่ถูกดึงมาเป็นข้อความ (String)
- ฟังก์ชัน `extract_data_from_website(**kwargs)` รับค่า URL ผ่าน kwargs ซึ่งเป็นข้อมูลพารามิเตอร์ และใช้ `ti` ในการจัดการ XCom ของ Apache Airflow

2) Process

- a. `get_data_page(url)`:
 - i. รับค่า URL ของหน้าเว็บ
 - ii. ใช้การเชื่อมต่อไปที่หน้าเว็บผ่าน HTTP request เพื่อนำข้อมูล HTML ของหน้าเว็บกลับมา
 - iii. ตรวจสอบว่าการดึงข้อมูลสำเร็จหรือไม่ ถ้าสำเร็จจะส่งค่า HTML กลับมา ถ้าไม่สำเร็จจะจัดการกับข้อผิดพลาด (เช่น การเชื่อมต่อหมดเวลา หรือการตอบกลับผิดพลาด)
- b. `get_data_data(html)`:
 - i. รับค่า HTML ในรูปแบบข้อความ
 - ii. แปลง HTML ข้อความให้เป็นโครงสร้าง soup ที่สามารถทำการค้นหาได้
 - iii. ค้นหาตารางที่มีคลาส "std100 hover sticky" และส่งตารางนั้นออกมา
- c. `extract_data_from_website(**kwargs)`:
 - i. รับค่า URL จาก kwargs
 - ii. เรียกฟังก์ชัน `get_data_page(url)` เพื่อดึง HTML ของหน้าเว็บ
 - iii. เรียกฟังก์ชัน `get_data_data(html)` เพื่อดึงตารางข้อมูลออกมาจาก HTML
 - iv. สร้างรายการเก็บข้อมูลแบบ List เพื่อจัดเก็บข้อมูลในรูปแบบ JSON
 - v. ดึงหัวตาราง (Header) โดยใช้ `find_all('th')`
 - vi. วนลูปข้อมูลในแต่ละแถวของตาราง (ข้ามแถวแรกที่เป็นหัวตาราง) ดึงข้อมูลในแต่ละคอลัมน์และจับคู่กับหัวตาราง สร้างเป็น Dictionary ที่มีชื่อคอลัมน์เป็นกุญแจ (Key) และข้อมูลในแถวเป็นค่า (Value)
 - vii. แปลงข้อมูลทั้งหมดเป็น JSON และใช้ `xcom_push` เพื่อส่งข้อมูลนี้ไปใช้ใน Airflow ผ่าน XCom

3) Output

- a. ฟังก์ชัน `get_data_page(url)` คืนค่า HTML ของหน้าเว็บที่เป็นข้อความ หรือส่งข้อผิดพลาดออกมาหากเกิดปัญหา
- b. ฟังก์ชัน `get_data_data(html)` คืนค่าตารางข้อมูลที่ดึงมาจาก HTML หรือคืนค่า None หากไม่พบตาราง
- c. ฟังก์ชัน `extract_data_from_website(**kwargs)` คืนค่า 0 เพื่อบอกว่าเสร็จสิ้นกระบวนการ

```

def get_data_page(url):
    import requests

    print("Getting data page...", url)

    try:
        response = requests.get(url, timeout=10)
        response.raise_for_status() # check if the request is successful

        return response.text
    except requests.RequestException as e:
        print(f"An error occurred: {e}")

def get_data_data(html):
    from bs4 import BeautifulSoup
    soup = BeautifulSoup(html, 'html.parser')
    table = soup.find("table", {"class": "std100 hover sticky"})
    return table

def extract_data_from_website(**kwargs):
    url = kwargs['url']
    html = get_data_page(url)
    table_html = get_data_data(html)

    data = []

    headers = [header.text for header in table_html.find_all('th')]
    for row in table_html.find_all('tr')[1:]: # Skip the header row
        values = [value.text for value in row.find_all('td')]
        row_dict = {headers[i]: values[i] for i in range(len(headers))}
        data.append(row_dict)

    json_rows = json.dumps(data)
    kwargs['ti'].xcom_push(key='rows', value=json_rows)
    # print(json_rows)

    return 0

```

รูปที่ 3.3 การสกัดข้อมูลหน้าเว็บ

3.2.2 Transform

Transform คือ กระบวนการเปลี่ยนรูปแบบข้อมูลเพื่อให้ได้ข้อมูลที่ตรงตามกับความต้องการ สำหรับการแปลงข้อมูลจะประกอบไปด้วยขั้นตอนดังต่อไปนี้ ซึ่งโค้ดจะถูกแสดงดังรูปที่ 3.4

1) Input

- a. ฟังก์ชัน `transform_website_data(**kwargs)` รับข้อมูลผ่าน `kwargs` โดยดึงข้อมูลจาก XCom ของ Apache Airflow ผ่าน `xcom_pull` โดย `key='rows'` และ `task_ids='extract_data_from_website'` ซึ่งเป็นข้อมูลในรูปแบบ JSON ที่เก็บใน XCom

2) Process

- a. `transform_website_data(**kwargs)`:
 - i. ดึงข้อมูล JSON จาก XCom โดยใช้ `xcom_pull` และแปลงข้อมูลจาก JSON กลับเป็น List หรือ Dictionary
 - ii. สร้าง DataFrame จากข้อมูลที่ได้รับโดยใช้เครื่องมือ `pandas` เพื่อให้ง่ายต่อการประมวลผล
 - iii. ทำการวนลูปในแต่ละคอลัมน์ของ DataFrame
 - iv. ถ้าคอลัมน์มีประเภทข้อมูลเป็น `object` และไม่ใช่คอลัมน์ "Year" (ปี)
 1. ลบเครื่องหมายค้นหลักพัน (เช่น เครื่องหมาย ,) ในข้อมูล
 2. ลบเครื่องหมาย % ออกจากข้อมูล
 3. แปลงค่าจาก String ให้เป็นข้อมูลประเภทตัวเลขทศนิยม (float)
 - v. ถ้าคอลัมน์ไม่เข้าข่ายเงื่อนไขข้างต้นจะข้ามไป
 - vi. หลังจากทำการปรับปรุงข้อมูลเสร็จแล้ว แปลง DataFrame เป็น JSON เพื่อส่งข้อมูลกลับไปยัง XCom ผ่าน `xcom_push` ให้ใช้ในกระบวนการถัดไปของ Airflow

3) Output

- a. ฟังก์ชันจะส่งค่า DataFrame ที่ถูกแปลงเป็น JSON กลับไปยัง XCom และพิมพ์ DataFrame ที่แปลงแล้วออกทางหน้าจอ
- b. ฟังก์ชันจะคืนค่า 0 เพื่อบอกว่ากระบวนการเสร็จสิ้น

```
def transform_website_data(**kwargs):
    data = kwargs['ti'].xcom_pull(key='rows', task_ids='extract_data_from_website')
    data = json.loads(data)
    inflation_df = pd.DataFrame(data)

    for i in inflation_df.columns:
        if inflation_df[i].dtype == 'object' and i != "Year" :
            inflation_df[i] = inflation_df[i].str.replace(',', '') # ลบเครื่องหมายคั่นหลักพัน
            inflation_df[i] = inflation_df[i].str.replace('%', '') # ลบเครื่องหมาย %
            inflation_df[i] = inflation_df[i].astype(float) # แปลงเป็น float
        else:
            continue

    # push to xcom
    kwargs['ti'].xcom_push(key='rows', value=inflation_df.to_json())

    print(inflation_df)
    return 0
```

รูปที่ 3.4 กระบวนการ Transform

3.2.3 Load

Load คือ การนำข้อมูลเข้าสู่ระบบปลายทางที่ต้องการในส่วนของการงานวิจัยนี้ได้นำข้อมูลเข้าสู่ Data Lake จะประกอบไปด้วยขั้นตอนดังต่อไปนี้ ซึ่งโค้ดจะถูกแสดงดังรูปที่ 3.5

1) Input

- a. ฟังก์ชัน write_website_data(**kwargs) รับข้อมูลจาก XCom ผ่าน xcom_pull โดยข้อมูลนี้มาจาก task transform_website_data ซึ่งเป็นข้อมูลที่ถูกแปลงจากเว็บไซต์และอยู่ในรูปแบบ JSON
- b. ใช้ OUTPUT_PATH เพื่อระบุเส้นทางในการบันทึกไฟล์บนเครื่อง และ ACCESS_KEY สำหรับการบันทึกไฟล์บนคลาวด์

2) Process

- a. write_website_data(**kwargs)
 - i. ดึงข้อมูล JSON จาก XCom และแปลงข้อมูลเป็น DataFrame โดยใช้ pandas
 - ii. กำหนดชื่อไฟล์ตามปีปัจจุบัน เช่น inflation_rates_2024.csv
 - iii. ตรวจสอบไฟล์ในเส้นทางบันทึก (OUTPUT_PATH) ว่ามีไฟล์ที่มีชื่อเดียวกันหรือไม่ โดยอ่านรายชื่อไฟล์ในไดเรกทอรี
 - iv. ถ้าไม่มีไฟล์ที่ชื่อเดียวกัน

1. สร้างไดเรกทอรี (หากไม่มี)
2. บันทึกข้อมูลเป็นไฟล์ CSV ลงในเครื่อง
3. พยายามบันทึกไฟล์ CSV ไปยังคลาวด์โดยใช้เส้นทางของ Azure Blob Storage (ผ่าน URL abfs://) และ ใช้ storage_options สำหรับการเชื่อมต่อกับบัญชี Azure
4. ถ้าเกิดข้อผิดพลาดในการบันทึกบนคลาวด์ ให้พิมพ์ข้อความแจ้งเตือนข้อผิดพลาด
5. ถ้าบันทึกข้อมูลสำเร็จ จะพิมพ์ข้อความว่าบันทึกข้อมูลแล้ว
- v. ถ้าไฟล์ที่มีชื่อเดียวกันอยู่แล้ว จะพิมพ์ข้อความแจ้งเตือนว่าไฟล์นี้มีอยู่บนคลาวด์แล้ว
- vi. สุดท้ายทำการบันทึกชื่อไฟล์ลงใน XCom โดยใช้ xcom_push เพื่อส่งค่าให้กับ task ถัดไป

3) Output

- a. ฟังก์ชันจะบันทึกข้อมูลในรูปแบบไฟล์ CSV ทั้งในเครื่องและบนคลาวด์ ถ้าสำเร็จ จะพิมพ์ข้อความว่า "Data saved" หากมีข้อผิดพลาดจะแจ้งเตือนข้อผิดพลาด
- b. ฟังก์ชันจะส่งค่าชื่อไฟล์ (file_name) ไปยัง XCom เพื่อใช้ใน task ถัดไป
- c. ฟังก์ชันจะส่งค่าชื่อไฟล์ (file_name) ไปยัง XCom เพื่อใช้ใน task ถัดไป

```

def write_website_data(**kwargs):

    data = kwargs['ti'].xcom_pull(key='rows', task_ids='transform_website_data')

    data = json.loads(data)
    data = pd.DataFrame(data)

    file_name = f'inflation_rates_{datetime.now().year}.csv'
    file_path = f'{OUTPUT_PATH}/{file_name}'
    files = os.listdir(OUTPUT_PATH)
    print("Files in output path:")

    arr_check_file = []
    for f in files:
        print(f)
        arr_check_file.append(f)
    if file_name not in arr_check_file:
        try:
            os.makedirs(os.path.dirname(file_path), exist_ok=True)
            data.to_csv(file_path, index=False)
            try:
                data.to_csv(f'abfs://dataeng@projectdataeng.dfs.core.window.net/data/{file_name}',
                            storage_options={
                                'account_name': 'projectdataeng',
                                'account_key': f'{ACCESS_KEY}'
                            }, index=False)
            except Exception as e:
                print(f"Error saving data on cloud: {e}")
            print(f"Data saved to {file_path}")
        except Exception as e:
            print(f"Error saving data: {e}")
    else:
        print(f"On cloud have this file name : {file_name}")


    kwargs['ti'].xcom_push(key='rows', value=file_name)
    return 0

```

รูปที่ 3.5 กระบวนการโหลดข้อมูลไปยัง Data Lake

3.3 Data Lake

Data lake คือ ที่เก็บขนาดใหญ่ที่สามารถเก็บข้อมูลได้ทุกรูปแบบจากหลายแหล่งโดยที่ไม่ต้องมีการแปลงข้อมูลก่อน โดยสามารถเก็บข้อมูลตั้งแต่ข้อมูลที่มีโครงสร้างชัดเจน (Structured Data) ข้อมูลกึ่งโครงสร้าง (Semi-Structured Data) และข้อมูลที่ไม่มีโครงสร้างแน่นอน (Unstructured Data) ซึ่งทางผู้วิจัยเลือกใช้บริการ Data Lake ของ Azure ซึ่งแสดงดังรูป 3.6



รูปที่ 3.6 Data Lake Storage

3.4 Data Warehouse

Datawarehouse คือ ระบบจัดเก็บข้อมูลที่มีการจัดระเบียบและแปลงรูปแบบข้อมูล เพื่อเก็บข้อมูลไว้เป็นส่วนกลาง (Centralized Repository) ซึ่งในส่วนของการงานวิจัยนี้ Data Warehouse มีโครงสร้างเป็นแบบ Star Schema ซึ่งแสดงดังรูป 3.7




รูปที่ 3.7 Data Warehouse


3.5 Data Visualization

Data Visualization คือ การนำข้อมูลหรือ Data ที่ผ่านกระบวนการวิเคราะห์และประมวลผล มานำเสนอในรูปแบบที่เข้าใจง่ายผ่านการมองเห็น ทำให้ผู้อ่านสามารถเข้าใจได้ทันทีว่าตัวชี้งานต้องการสื่อสารอะไร ทำให้ชี้ประเด็นของข้อมูลได้อย่างตรงจุด ซึ่งจะประกอบไปด้วยขั้นตอนดังต่อไปนี้

- 1) การเชื่อมต่อ Power BI เข้ากับ Azure Synapse โดยทำการเลือกตามหมายเลขที่มีการกำหนดไว้ในรูป 3.8 ตามลำดับจากน้อยไปมาก หลังทำการกด Connect กับ Azure Synapse สำเร็จถัดไปทำการเลือก Workspace และ Table ที่ต้องการหลังจากนั้นกดปุ่ม Load เพื่อนำข้อมูลเข้าสู่ Power BI ซึ่งแสดงดังรูป 3.9




รูปที่ 3.8 การนำข้อมูลเข้าสู่ Power BI 1



รูปที่ 3.9 การนำข้อมูลเข้าสู่ Power BI 2

- 2) การสร้าง Visual โดยทำการเลือก Visual ที่ต้องการจากรูปที่ 3.10 เลือก Stack Bar Chart หลังจากนั้นเลือกนำ Data มาวางไว้ในกรอบสี่เหลี่ยม



รูปที่ 3.10 การสร้าง Visual


บทที่ 4

ผลการดำเนินการวิจัย

ในบทนี้จะกล่าวถึงผลลัพธ์ที่ได้จากวิธีการดำเนินการวิจัย โดยมีหัวข้อดังนี้ 4.1) ลักษณะผลลัพธ์ที่ได้จากกระบวนการ ETL 4.2) การอธิบายความสัมพันธ์ระหว่างข้อมูล 4.3) Data Visualization

4.1 ลักษณะผลลัพธ์ที่ได้จากกระบวนการ ETL

โดยผู้วิจัยมีการดำเนินการผ่านกระบวนการ ETL ทำให้ได้ข้อมูลที่ถูกจัดเก็บเป็นลักษณะของไฟล์ CSV และผลลัพธ์ของ Log ที่แสดงผ่าน Apache Airflow ดังรูปที่ 4.1 และ 4.2 หลังจากนั้นข้อมูลจะถูกบันทึกไปยัง Data Lake หลังจากนั้นข้อมูลจะถูกย้ายไปยัง Data Warehouse ซึ่งจะแสดงให้เห็นดังรูปที่ 3.9 ที่มีการเชื่อมต่อไปยัง Azure Synapse Analytics ซึ่งเป็นแพลตฟอร์มที่ทำหน้าที่เป็น Data Warehouse



รูปที่ 4.1 แสดงว่า Task ที่ถูกจัดการโดย Apache Airflow ไม่พบข้อผิดพลาด

```

a86e1e3d948c
*** Found local files:
*** * /opt/airflow/logs/dag_id=inflation_dag/run_id>manual__2024-08-20T13:47:50.491210+00:00/task_id=write_website_data/attempt=1.log
[2024-08-20, 20:48:09 +07] {local_task_job_runner.py:120} ► Pre task execution logs
[2024-08-20, 20:48:09 +07] {logging_mixin.py:188} INFO - Files in output path:
[2024-08-20, 20:48:09 +07] {logging_mixin.py:188} INFO - product_category_name_translation.csv
[2024-08-20, 20:48:09 +07] {logging_mixin.py:188} INFO - olist_sellers_dataset.csv
[2024-08-20, 20:48:09 +07] {logging_mixin.py:188} INFO - olist_customers_dataset.csv
[2024-08-20, 20:48:09 +07] {logging_mixin.py:188} INFO - olist_order_reviews_dataset.csv
[2024-08-20, 20:48:09 +07] {logging_mixin.py:188} INFO - olist_order_items_dataset.csv
[2024-08-20, 20:48:09 +07] {logging_mixin.py:188} INFO - inflation_rates_2024.csv
[2024-08-20, 20:48:09 +07] {logging_mixin.py:188} INFO - olist_orders_dataset.csv
[2024-08-20, 20:48:09 +07] {logging_mixin.py:188} INFO - olist_order_payments_dataset.csv
[2024-08-20, 20:48:09 +07] {logging_mixin.py:188} INFO - olist_geolocation_dataset.csv
[2024-08-20, 20:48:09 +07] {logging_mixin.py:188} INFO - On cloud have this file name : inflation_rates_2024.csv
[2024-08-20, 20:48:09 +07] {python.py:237} INFO - Done. Returned value was: None
[2024-08-20, 20:48:09 +07] {taskinstance.py:441} ► Post task execution logs
  
```

รูปที่ 4.2 Log ของกระบวนการ write_website_data

4.2 การอธิบายความสัมพันธ์ระหว่างข้อมูล

จากรูปที่ 3.10 แสดงโครงสร้างความสัมพันธ์ของข้อมูล ชุดข้อมูลประกอบด้วยหลายตารางที่เชื่อมโยงกัน โดยมีตารางหลักคือ olist_orders_dataset ซึ่งทำหน้าที่เป็น Fact Table เชื่อมต่อกับตารางต่างๆ ดังนี้:

4.2.1 olist_customers_dataset

เชื่อมต่อกับ olist_orders_dataset ผ่าน customer_id เพื่อดึงข้อมูลลูกค้าที่ทำการสั่งซื้อ โดยมีรายละเอียดของลูกค้า เช่น เมือง (customer_city) รัฐ (customer_state) และรหัสไปรษณีย์ (customer_zip_code_prefix)

4.2.2 olist_geolocation_dataset

เชื่อมต่อกับ olist_customers_dataset ผ่าน geolocation_zip_code_prefix เพื่อระบุตำแหน่งทางภูมิศาสตร์ของลูกค้าและผู้ขาย เช่น ละติจูด (geolocation_lat) และลองจิจูด (geolocation_lng)

4.2.3 olist_order_reviews_dataset

เชื่อมต่อกับ olist_orders_dataset ผ่าน order_id เพื่อดึงข้อมูลรีวิวจากลูกค้า โดยประกอบด้วยคะแนนรีวิว (review_score) คำแสดงความคิดเห็น (review_comment_message) และวันที่รีวิว (review_creation_date)

4.2.4 olist_order_payments_dataset

เชื่อมต่อกับ olist_orders_dataset ผ่าน order_id เพื่อดึงข้อมูลการชำระเงิน เช่น จำนวนงวดการชำระ (payment_installments) ประเภทการชำระ (payment_type) และมูลค่าการชำระ (payment_value)

4.2.5 olist_order_items_dataset

เชื่อมต่อกับ olist_orders_dataset ผ่าน order_id และกับ olist_products_dataset ผ่าน product_id เพื่อดึงข้อมูลรายการสินค้าที่สั่งซื้อ เช่น ราคาสินค้า (price) มูลค่าการขนส่ง (freight_value) และวันที่ส่งสินค้า (shipping_limit_date)

4.2.6 olist_products_dataset

เชื่อมต่อกับ olist_order_items_dataset ผ่าน product_id เพื่อดึงข้อมูลสินค้าที่ถูกสั่งซื้อ เช่น ขนาด (product_length_cm product_height_cm product_width_cm) น้ำหนัก (product_weight_g) และคำอธิบายสินค้า (product_description_lenght)

4.2.7 olist_sellers_dataset

เชื่อมต่อกับ olist_order_items_dataset ผ่าน seller_id เพื่อดึงข้อมูลผู้ขาย เช่น เมือง (seller_city) รัฐ (seller_state) และรหัสไปรษณีย์ (seller_zip_code_prefix)

4.2.8 product_category_name_translation


เชื่อมต่อกับ olist_products_dataset ผ่าน product_category_name เพื่อแปลงชื่อหมวดหมู่สินค้าเป็นภาษาอังกฤษ (product_category_name_english)

4.2.9 inflation_rate

เชื่อมต่อกับ olist_orders_dataset ผ่าน Year เพื่อดึงข้อมูลอัตราเงินเฟ้อจากประเทศต่างๆ เช่น บราซิล (Brazil) สหภาพยุโรป (EU) และอเมริกา (USA)

4.3 การวิเคราะห์ข้อมูลโดยใช้โปรแกรม Power BI

โดยผู้วิจัยได้สร้างแดชบอร์ดที่แสดงดังรูป 4.3 ซึ่งให้ข้อมูลเกี่ยวกับพฤติกรรม การซื้อขายสินค้าภายใน Olist Store ตั้งแต่ยอดขายรวม วิธีการชำระเงินที่นิยม หมวดหมู่สินค้าที่ขายดีที่สุด ไปจนถึงการเปรียบเทียบยอดขายในแต่ละเดือนและผลกระทบของอัตราเงินเฟ้อต่อราคาสินค้า นอกจากนี้ยังแสดงให้เห็นการกระจายตัวของคำสั่งซื้อในภูมิภาคต่างๆ ของบราซิล



รูปที่ 4.3 Sales Dashboards

บทที่ 5

การทดสอบ

หลังจากที่มีการดำเนินการวิจัยจะต้องมีการทดสอบเพื่อให้มั่นใจว่า กระบวนการวิศวกรรมข้อมูลสามารถใช้งานได้ตามวัตถุประสงค์อีกทั้งเพื่อค้นหาข้อผิดพลาดที่เกิดขึ้นในกระบวนการ

5.1 กรณีทดสอบแบบแยกหน้าที่การทำงานของแต่ละกระบวนการวิศวกรรมข้อมูล

จากการทดสอบการทำงานของแต่ละกระบวนการวิศวกรรมข้อมูลมีดังนี้ 1) กรณีทดสอบ 2) ผลที่คาดหวังดัง 3) ผลการทดสอบ ดังตารางที่ 5.1

ตารางที่ 5.1 กรณีทดสอบ ผลลัพธ์ที่คาดหวัง และ ผลการทดสอบ

ลำดับ	กรณีทดสอบ	ผลลัพธ์ที่คาดหวัง	ผลการทดสอบ (ผ่าน/ไม่ผ่าน)
1	ขั้นตอนกระบวนการ ETL	ไม่พบข้อผิดพลาดที่แสดงผ่าน Log ของ Apache Airflow	ผ่าน
2	Data Lake	พบข้อมูลลักษณะไฟล์ CSV ใน Data Lake	ผ่าน
3	Data Warehouse	ข้อมูลถูกย้ายไปเก็บใน Azure Synapse Analytics	ผ่าน
4	Data Visualization	สามารถดึงข้อมูล Data Warehouse และ สร้างเป็นแดชบอร์ด ที่สามารถทำความเข้าใจได้ง่าย	ผ่าน

บทที่ 6

บทสรุป

ในบทที่ 6 เป็นบทสรุปจะกล่าวถึงในส่วนของการหลักและงานที่ได้รับมอบหมายในระหว่างฝึกสหกิจซึ่งประกอบด้วยหัวข้อดังนี้ 6.1) สรุปผลการดำเนินโครงการ 6.2) ข้อจำกัด 6.3) ข้อเสนอแนะ 6.4) สรุปผลการปฏิบัติงาน

6.1 สรุปผลการดำเนินโครงการ

การพัฒนา Data Pipeline ก่อนนำข้อมูลมาวิเคราะห์และออกแดชบอร์ดเพื่อศึกษากระบวนการ Extract, Transform, Load และการใช้งาน Apache Airflow รวมถึงได้ทราบถึงประโยชน์ของ Data Lake และ Data Warehouse และท้ายที่สุดได้เข้าใจการใช้งาน Cloud เบื้องต้น

6.2 ข้อจำกัด

เนื่องจากการใช้งาน Cloud Computing มีค่าใช้จ่ายที่สูงมากทำให้ไม่สามารถนำ Apache Airflow ไปใช้งานบน Cloud ได้ และ Apache Airflow มีความต้องการทรัพยากรของระบบที่สูงทำให้ต้องใช้คอมพิวเตอร์ที่มีสเปคที่ค่อนข้างสูงในการพัฒนา Data Pipeline

6.3 ข้อเสนอแนะ

ควรมีการใช้งาน Azure Data Factory เป็นตัวกลางในการประมวลผลข้อมูลจาก Data Lake หนึ่งไปยังอีก Data Lake ก่อนนำเข้า Data Warehouse เนื่องจากการใช้งานสถาปัตยกรรมลักษณะข้างต้นเหมาะกับองค์กรที่มีข้อมูลขนาดใหญ่และซับซ้อนมากกว่า

6.4 สรุปผลการปฏิบัติงาน

ในช่วงที่มีการฝึกสหกิจ ทางพี่เลี้ยงได้มอบหมายงานต่าง ๆ ดังนี้

1. พัฒนาแดชบอร์ดและจัดทำคู่มือการใช้งานแดชบอร์ด
2. จัดทำ Data Dictionary
3. จัดทำคู่มือที่เกี่ยวข้องกับ Power BI พร้อมนำเสนอให้แก่ทีม UX/UI
4. จัดทำคู่มือการใช้งาน Power Automate, Power BI real time และนำเสนอ
5. จัดทำคู่มือการใช้งาน Template บน Power BI
6. เปรียบเทียบความแตกต่างของเครื่องมือ BI ระหว่าง Power BI กับ Looker
7. ปรับปรุงคู่มือ CR เรื่องการขอเพิ่มลดเปลี่ยนแปลงสิทธิ์บนระบบ Mamori

เอกสารอ้างอิง (References)

- [1] Google Cloud Documentation แหล่งที่มา URL: <https://cloud.google.com/docs> :เข้าถึงเมื่อ 10 สิงหาคม 2567
- [2] Product overview of Cloud Storage แหล่งที่มา URL: <https://cloud.google.com/storage/docs/introduction> :เข้าถึงเมื่อ 10 สิงหาคม 2567
- [3] BigQuery overview แหล่งที่มา URL: <https://cloud.google.com/bigquery/docs/introduction> :เข้าถึงเมื่อ 10 สิงหาคม 2567
- [4] Microsoft Azure แหล่งที่มา URL: <https://learn.microsoft.com/bs-latn-ba/azure/cloud-services/cloud-services-choose-me> :เข้าถึงเมื่อ 10 สิงหาคม 2567
- [5] Azure Repos แหล่งที่มา URL: <https://learn.microsoft.com/en-us/azure/devops/repos/get-started/what-is-repos?view=azure-devops> :เข้าถึงเมื่อ 10 สิงหาคม 2567
- [6] Azure Pipelines แหล่งที่มา URL: <https://learn.microsoft.com/en-us/azure/devops/pipelines/get-started/what-is-azure-pipelines?view=azure-devops> :เข้าถึงเมื่อ 10 สิงหาคม 2567
- [7] Azure data lake gen2 แหล่งที่มา URL: <https://learn.microsoft.com/en-us/azure/storage/blobs/data-lake-storage-introduction> :เข้าถึงเมื่อ 10 สิงหาคม 2567
- [8] Azure Synapse Analytics แหล่งที่มา URL: <https://www.fusionsol.com/blog/azure-synapse/> :เข้าถึงเมื่อ 10 สิงหาคม 2567
- [9] Power BI แหล่งที่มา URL: <https://learn.microsoft.com/en-us/power-bi/fundamentals/power-bi-overview> :เข้าถึงเมื่อ 10 สิงหาคม 2567
- [10] รายงานใน Power BI แหล่งที่มา URL: <https://learn.microsoft.com/th-th/power-bi/consumer/end-user-reports> :เข้าถึงเมื่อ 10 สิงหาคม 2567
- [11] แบบจำลองความหมาย แหล่งที่มา URL: <https://learn.microsoft.com/th-th/power-bi/connect-data/service-datasets-understand> :เข้าถึงเมื่อ 10 สิงหาคม 2567
- [12] แดชบอร์ด แหล่งที่มา URL: <https://learn.microsoft.com/th-th/power-bi/consumer/end-user-dashboards> :เข้าถึงเมื่อ 10 สิงหาคม 2567
- [13] Pentaho แหล่งที่มา URL: <https://www.stream.co.th/pentaho-data-analytics-tools/> :เข้าถึงเมื่อ 10 สิงหาคม 2567

[14] Airflow แหล่งที่มา URL: <https://www.thedataengineeringbook.online/docs/apache-airflow> :
เข้าถึงเมื่อ 10 สิงหาคม 2567

[15] DAG แหล่งที่มา URL: <https://www.thedataengineeringbook.online/docs/apache-airflow#dag> :
เข้าถึงเมื่อ 10 สิงหาคม 2567

[16] Docker แหล่งที่มา URL: <https://docs.docker.com/build-cloud/> :เข้าถึงเมื่อ 10 สิงหาคม 2567

[17] Data Lake & Data warehouse แหล่งที่มา URL: <https://blog.datath.com/database-data-warehouse-data-lake/> :เข้าถึงเมื่อ 10 สิงหาคม 2567

[18] Data Pipeline แหล่งที่มา URL: <https://blog.datath.com/etl-คืออะไร/> :เข้าถึงเมื่อ 10 สิงหาคม 2567

[19] PostgreSQL แหล่งที่มา URL: <https://appmaster.io/th/blog/postgresql-khuue-aair> :เข้าถึงเมื่อ 10 สิงหาคม 2567

[20] BeautifulSoup แหล่งที่มา URL: <https://zixzax.net/web-development/what-is-web-scraping/> :
เข้าถึงเมื่อ 10 สิงหาคม 2567

[21] Python แหล่งที่มา URL: <https://blog.skooldio.com/what-is-python/> :เข้าถึงเมื่อ 10 สิงหาคม 2567

หนังสือยินยอมให้ข้อมูลเพื่อการศึกษา และเผยแพร่ผลการศึกษาสหกิจศึกษา

23 กันยายน 2567

หนังสือฉบับนี้ ข้าพเจ้า ณัฐสิริ ตันติขจร ในนาม บริษัท ซีพีเอฟ ไอทีเซ็นเตอร์ จำกัด
ที่อยู่ อาคารซี.พี.ทาวเวอร์ ถ.สีลม แขวงสีลม เขตบางรัก กรุงเทพมหานคร 10500
ขอทำหนังสือฉบับนี้เพื่อเป็นหลักฐานแสดงว่า ข้าพเจ้าได้รับทราบและยินยอมให้ นาย ธนธรณ์ บุญเชิด รหัสนักศึกษา
640510658 สังกัดภาควิชาวิทยาการคอมพิวเตอร์ คณะวิทยาศาสตร์ มหาวิทยาลัยเชียงใหม่ ผู้เข้าร่วมโครงการสหกิจศึกษา
ในภาคการเรียนที่ 1 ปีการศึกษา 2567 ณ.หน่วยงานของข้าพเจ้า ตั้งแต่วันที่ 1 เมษายน 2567 ถึงวันที่ 31 ตุลาคม 2567
ผู้ศึกษาสามารถเก็บข้อมูล ณ หน่วยงานของข้าพเจ้าตามคำชี้แจงของผู้ศึกษา
และอนุญาตให้นำผลการศึกษาและปฏิบัติงานเผยแพร่สู่สาธารณะได้

ทั้งนี้หากผู้ศึกษาได้กระทำภายในขอบเขตอำนาจของหนังสือยินยอมฉบับนี้ให้มีผลสมบูรณ์และชอบด้วยกฎหมายทุก
ประการ และหากมีผลกระทบหรือเกิดความเสียหายขึ้นจะไม่มี การเรียกร้องแต่อย่างใด เพื่อเป็นหลักฐานแห่งความยินยอมนี้
ข้าพเจ้าได้ลงลายมือชื่อและประทับตราไว้

NUTSIRI TUNTAKAJORN

[ลายมือชื่อผู้มีอำนาจกระทำการแทนนิติบุคคล]

September 23, 2024



Certificate of Completion

Document Number: DS-GA-202409-25635

Subject: หนังสือยินยอมเผยแพร่ผลการศึกษาศึกษาสหกิจธนธรณ์ บุญเชิด

Requester Name: Thanaton Booncherd

Number of Document Pages: 1

Document Sealing: Enable

Sealing Type: Company Certificate (Section 28)

Document Status: Approved

Requester Email: t-thanaton.boon@axons.in.th

Number of Signatures: 1

Certificate Sealing Name: CPF IT Center Company Limited
<infosec@cpf.co.th>

Sealed: 23/09/2024 05:58:03 PM +0700

Signer Information

Name: NUTSIRI TUNTIKAJORN

Email: Nutsiri.Tun@axonstech.com

Account Type: Corporate Email

Two-Factor Authentication: Disable

Signature Type: E-Signature (Section 9)

Signature

Signature:

NUTSIRI TUNTIKAJORN

Signature Image Type: Sign by Typing

Signed: 23/09/2024 05:58:00 PM +0700